

وزارت علوم، تحقیقات و فناوری



دانشکده علوم ریاضی

پیش‌بینی چندمتغیره‌ی هوا با شبکه‌های بازگشتی و تابع زیان وزن‌دار
افق‌محور آگاه از GARCH

نام استاد: دکتر هادی فراهانی

نام دستیار: آقای مبین نثاری

نام دانشجو: ناهید حاتمی بلاسی

شماره دانشجویی: ۴۰۴۴۲۲۲۰۷

تابستان ۱۴۰۵

مقدمه :

پیش‌بینی دقیق پدیده‌های هواشناسی یکی از چالش‌های مهم علوم زمین و یادگیری ماشین می‌باشد و بسیاری از تصمیم‌ها از برنامه‌ریزی کشاورزی و جلوگیری با بلاهای طبیعی نیاز به بررسی وضعیت هوا در ساعات و روزهای آینده وابسته دارد. با رشد مدل‌های یادگیری عمیق، شبکه‌های بازگشتی مانند LSTM و GRU توانسته‌اند با یادگیری الگوهای زمانی، از روشهای آماری کلاسیک گامی فراتر بروند.

۱. مسئله و هدف پژوهش

در این پژوهش دو متغیر مهم هواشناسی دمای هوا (T) و رطوبت نسبی (rh) رو چند قدم جلوتر پیش‌بینی می‌شود. برای این کار به یک پنجره‌ی لغزان از قرائت‌های ۱۴ حسگر هواشناسی در گذشته بررسی می‌شود تا بتوان آینده را حدس زد. همچنین در این پژوهش با سه افق پیش‌بینی مختلف، به بررسی خطا پرداخته می‌شود یعنی وقتی افق دورتر میشه، رفتار خطا چطور عمل می‌کند، به گونه‌ای انباشت خطا با افزایش افق که در این مدل پیش‌بینی بلندمدت وجود دارد.

جدول ۱- افق‌های پیش‌بینی

افق پیش‌بینی	معادل زمانی تقریبی
۶ گام	حدود ۶ ساعت آینده
۲۴ گام	حدود ۱ روز آینده
۷۲ گام	حدود ۳ روز آینده

در جدول ۱، سه افق پیش‌بینی در نظر گرفته شده است همچنین داده‌ها ساعتی نمونه‌برداری شدن، بنابراین هر گام برابر با یک ساعت است.

علاوه بر مقایسه‌ی سه معماری‌های استاندارد (LSTM، GRU، Seq2Seq) در برابر یک baseline ساده، این پروژه یک مشارکت اصیل معرفی و به‌طور تجربی ارزیابی می‌کند: تابع زبانی که هم‌زمان به گام‌های دورتر افق (زیرا پیش‌بینی سخت‌تر در گام‌های دورتر افق سخت‌تر است) و به دوره‌های زمانی پرنوسان (بر اساس یک مدل GARCH) وزن بیشتری می‌دهد.

۲. داده پژوهش

۱.۲ مجموعه داده

دیتاست مورد استفاده، Jena Climate است که توسط مؤسسه‌ی Max Planck برای بیوژئوشیمی در ایستگاه هواشناسی Weather Station، پردیس Beutenberg، شهر Jena آلمان گردآوری شده است. این دیتاست شامل حدود ۴۲۰۰۵۵۱ رکورد با تفکیک زمانی ۱۰ دقیقه‌ای و ۱۴ متغیر هواشناسی (دما، فشار، رطوبت، سرعت و جهت باد، تابش خورشیدی، فشار بخار آب و غیره) است. دسترسی به داده از طریق `tf.keras.utils.get_file` و آینه‌ی رسمی گوگل

storage.googleapis.com/tensorflow/tf-keras-datasets/jena_climate_۲۰۰۹_۲۰۱۶.csv.zip

انجام شده است .

متغیر	نماد	واحد	توضیحات
تاریخ و زمان	Date Time	—	زمان قرائت هر رکورد
فشار جو	P	mbar	فشار هوا در سطح ایستگاه
دمای هوا	T	درجه سلسیوس	دمای هوا که یکی از دو هدف پیش‌بینی
دمای پتانسیل	Tpot	کلوین	دمایی که هوا اگر به فشار مرجع برسه وجو دارد.
دمای نقطه‌ی شبنم	Tdew	درجه سلسیوس	دمایی که در آن هوا به اشباع می‌رسد
رطوبت نسبی	Rh	درصد	نسبت رطوبت موجود به رطوبت اشباع (هدف دوم)
فشار بخار اشباع	VPmax	mbar	حداکثر فشار بخار آب ممکن
فشار بخار واقعی	VPact	mbar	فشار بخار آبی که واقعاً در هوا است
کمبود فشار بخار	VPdef	mbar	اختلاف VPact و VPmax
رطوبت ویژه	Sh	g/kg	جرم بخار آب به ازای جرم هوا
غلظت آب	OC ₂ H	mmol/mol	نسبت مولکول‌های آب توی هوا
چگالی هوا	rho	g/m ³	جرم هوا در واحد حجم
سرعت باد	wv	m/s	سرعت متوسط باد
حداکثر سرعت باد	max. wv	m/s	بیشترین سرعت ثبت‌شده‌ی باد
جهت باد	wd	درجه	جهت حرکت باد از ۰ تا ۳۶۰ درجه

۲.۲ پیش‌پردازش

مهم‌ترین عوامل پیش‌پردازش شامل موارد زیر است.

۱. نمونه‌برداری ساعتی یعنی از هر ۶ رکورد ۱۰ دقیقه‌ای، یکی نگه داشته می‌شود تا طول دنباله و نویز حسگر کاهش یابد.
۲. اصلاح مقادیر نامعتبر سرعت باد (در ستون‌های wv (m/s) و max. wv (m/s) با جایگزینی صفر (بعضی رکوردها که خطای ۹۹۹۹ داشتند)
۳. تبدیل جهت باد (درجه) به سرعت به بردار دکارتی Wx، Wy چون جهت به‌تنهایی کمیتهی تناوبی و برای یک ورودی خطی گمراه‌کننده است. (مثلاً ۳۵۹ درجه و ۱ درجه تقریباً همون جهتن ولی عددشون خیلی فرق داشت. برای اینکه ورودی خطی مدل گمراه نشه، جهت و سرعت رو به دو مؤلفه‌ی Wx و Wy بردار دکارتی تبدیل شده است.)
۴. ویژگی‌های چرخه‌ای زمان: sin/cos ساعت روز (Day sin/cos) و روز سال (Year sin/cos) به‌جای timestamp خام.
۵. ویژگی‌های چرخه‌ای زمان: sin/cos ساعت روز (Day sin/cos) و روز سال (Year sin/cos) به‌جای timestamp خام تا ماهیت تناوبی زمان در مدل دیده شود.
۶. تقسیم زمانی (نه تصادفی) با نسبت ۷۰٪ / ۲۰٪ / ۱۰٪ برای train / validation / test.
۷. نرمال‌سازی z-score، با میانگین و انحراف‌معیار محاسبه‌شده فقط از مجموعه‌ی train، برای جلوگیری از نشت داده (data leakage) از آینده به گذشته.

۰.۳ روش

۱.۳ پنجره‌بندی

قبل از رسیدن به هر مدل، داده باید از یک دنباله‌ی زمانی تخت (flat) به جفت‌های (ورودی، برچسب) تبدیل شود. کلاس WindowGenerator این کار را انجام می‌دهد: ابتدا تعریف هندسه‌ی پنجره که مشخص می‌کند هر نمونه چقدر از گذشته رو نشون میده و چقدر از آینده رو باید حدس بزند که شامل input_width برابر ۲۴ است یعنی ۲۴ ساعت از داده‌ی ساعتی به عنوان ورودی گذشته است. این طول عمداً انتخاب شده چون به بازه‌ی کامل ۲۴ ساعته که چرخه‌ی روزانه‌ی دما و تابش در آن قرار بگیرد، بدون اینکه دنباله بلند بشه که آموزش مدل کند شود. همچنین shift = label_width یعنی پنجره‌ی افق (برچسب‌ها) بلاواسطه بعد از پنجره‌ی ورودی قرار می‌گیرد؛ هیچ فاصله‌ای بین گذشته و آینده گذاشته نمی‌شود و سه افق روی همین یک کلاس اجرا می‌شوند. گام بعدی جدا کردن ورودی از برچسب است یعنی به بلوک خام به طول input_width + shift به دو تکه بریده می‌شود که قسمت اول ورودی مدل میشه و قسمت دوم برچسب هدف است. در نهایت ساخت واقعی پنجره‌ها با استفاده از tf.keras.utils.timeseries_dataset_from_array و sequence_stride=۱، همه‌ی پنجره‌های ممکن رو استخراج میکنیم نه اینکه فقط از هر چند گام به نمونه برداریم. به این ترتیب حداکثر استفاده از داده‌ی موجود می‌شود.

۲.۳ مدل‌ها

چهار مدل با بودجه‌ی محاسباتی و epoch یکسان آموزش دیده‌اند تا مقایسه منصفانه باشد. اولین و ساده‌ترین معماری build_naive_baseline محسوب می‌شود که بر اساس آخرین مقدار مشاهده‌شده (T و rh در آخرین گام ورودی) برای همه‌ی label_width گام افق بدون هیچ یادگیری تکرار می‌شود. این baseline معیار حداقل سودمندی است یعنی هر مدل یادگیری که نتواند از آن بهتر عمل کند، عملاً بی‌فایده است. مدل‌های بعدی build_lstm و build_gru هستند که دارای یک لایه‌ی بازگشتی (LSTM یا GRU با ۳۲ واحد و return_sequences=False) کل پنجره‌ی ۲۴ گامه را در یک بردار حالت نهایی فشرده می‌کند. همچنین یک لایه Dense این بردار رو مستقیم به اندازه‌ی label_width × num_label_features بسط می‌دهد و بعد Reshape اون رو به شکل (label_width, num_label_features) حاصل می‌کند و کل افق توی یک گام forward پیشبینی می‌شود اما در معماری LSTM سه گیت مجزای فراموشی/ورودی/خروجی طراحی شده تا وابستگی‌های بلندمدت رو بهتر نگه دارد و در معماری GRU نسخه‌ی ساده‌تر با فقط دو گیت (update/reset) و پارامتر کمتر دارد که سریع‌تر عمل می‌کند. مدل Seq2Seq یک GRU رمزگذار (encoder) کل پنجره‌ی ورودی را می‌خواند و حالت نهایی‌اش را به رمزگشا (decoder) می‌دهد. رمزگشا با GRUCell، گام به گام و به صورت خودبازگشتی (autoregressive) عمل می‌کند که خروجی هر گام، ورودی گام بعدی دیکودر می‌شود و الهام گرفته از معماری [Sutskever et al., ۲۰۱۴] که اصلاً برای ترجمه‌ی ماشینی طراحی شده بود. اولین ورودی دیکودر، آخرین مقدار مشاهده‌شده‌ی واقعی (نه صفر) است، یک warm-start ساده که به دیکودر کمک می‌کند از یک نقطه‌ی معنادار شروع کند. همچنین همه‌ی مدل‌ها (baseline به جز، چون یادگیری ندارد). دقیقاً از همین تابع مشترک زیر عبور می‌کنند.

Adam (lr=۱e-۳)، EarlyStopping، val_loss (patience=۳، restore_best_weights=True) حداکثر ۲۰ epoch.

۳. مشارکت خلاقانه

ایده خلاقانه این پژوهش (GHW) GARCH-Aware Horizon-Weighted Loss است. نقطه‌ی شروع ایده، یک مشاهده‌ی ساده در نمودارهای MAE برحسب گام بود: خطای مدل با گذر از گام اول افق به گام آخر، یکنواخت و صاف رشد نمی‌کند بلکه در برخی بازه‌های زمانی (وقتی جو ناپایدار است و جبهه‌ی هوا در حال عبور است) خطا به صورت دسته‌جمعی و ناگهانی بزرگ می‌شود، و در بازه‌های آرام هوا، خطا برای مدت طولانی کوچک و پایدار می‌ماند. این الگو که خطاهای بزرگ در کنار هم خوشه می‌بندند و خطاهای کوچک هم در کنار هم خوشه می‌بندند دقیقاً همان پدیده‌ای است که در اقتصادسنجی مالی «خوشه‌بندی نوسان» (volatility clustering) نامیده می‌شود: روزهای پرنوسان بازار سهام، کنار هم می‌آیند و روزهای آرام هم کنار هم. برای مدل کردن دقیقاً همین پدیده در بازه‌های مالی، Engle (۱۹۸۲) مدل ARCH و سپس Bollerslev (۱۹۸۶) نسخه‌ی تعمیم‌یافته‌ی آن یعنی GARCH را معرفی کردند: مدلی که واریانس در هر لحظه (σ_t^2) را نه ثابت، بلکه تابعی از شوک‌های اخیر و واریانس‌های اخیر خودش در نظر می‌گیرد. ایده‌ی این پروژه، وام گرفتن همین ابزار از حوزه‌ی مالی و به کار بردن آن نه روی قیمت خام دما (چون دما خودش یک سری فصلی/روندی است که LSTM با طراحی‌اش قرار است آن را یاد بگیرد)، بلکه روی residual (خطای) یک مدل پیش‌بینی سبک بود یعنی همان چیزی که واقعاً «نویز غیرقابل پیش‌بینی» مدل است. اگر این residual هم خوشه‌بندی نوسان نشان دهد، یک GARCH(۱,۱) می‌تواند σ_t را در هر لحظه برآورد کند و به ما بگوید که این لحظه، مدل چقدر باید نامطمئن باشد. همچنین یک تابع زیان MSE ساده، به هر نمونه (چه در بازه‌ی آرام چه در بازه‌ی پرنوسان) وزن یکسان می‌دهد. اما اگر بدانیم فلان بازه‌ی زمانی ذاتاً پرنوسان و سخت است، منطقی است که یا (۱) کمتر روی آن اصرار کنیم چون شاید غیرقابل یادگیری باشد (وزن دهی معکوس واریانس، شبیه weighted least squares در آمار کلاسیک)، یا برعکس (۲) دقیقاً روی همین بازه‌ها بیشتر تمرکز کنیم چون مهم‌ترین لحظات عملی برای کاربر همین جاهاست (جبهه‌ی هوا). این پروژه گزینه‌ی اول را انتخاب کرد وزن معکوس واریانس ($\sigma_t^2/1$) چون در چارچوب weighted regression استاندارد است و پایه‌ی نظری روشن‌تری دارد.

۱.۳ فرضیه‌های پژوهش

۱.۱.۳ فرضیه‌ی اصلی پژوهش

اگر تابع زیان LSTM را از MSE ساده به وزنی تغییر دهیم که حاصل ضرب (۱) یک وزن صریح و فزاینده‌ی افق ($w_{horizon}(h)$) و (۲) معکوس واریانس شرطی GARCH برازش‌شده روی residual تک‌گامی مدل ($\sigma_t^2/1$) باشد، آنگاه مدل حاصل (LSTM+GHW) باید روی هر سه افق (۶، ۲۴، ۷۲ گام) از سه رقیب LSTM ساده‌ی بدون وزن دهی، و دو نسخه‌ی تک‌مکانیزمی (فقط افق و فقط نوسان) از نظر MAE و RMSE بهتر عمل کند؛ و این برتری باید در افق‌های بلندتر (۲۴ و ۷۲ گام) بزرگ‌تر از افق کوتاه (۶ گام) باشد، چون در آن جا هم انباشت خطای افق و هم فرصت تفکیک بازه‌های پرنوسان از آرام بیشتر خودش را نشان می‌دهد.

۲.۱.۳ فرضیه فرعی پژوهش

اگر ایده‌ی اصلی درست باشد، باید رابطه‌ی $MAE(ترکیبی) > min(MAE(فقط-افق), MAE(فقط-نوسان)) > MAE(LSTM ساده)$ در داده‌های واقعی دیده شود یعنی ترکیب باید از بهترین هر کدام به تنهایی هم بهتر باشد، نه فقط از LSTM ساده.

۱.۴ پیگر بندی آموزش

آموزش همه‌ی مدل‌ها با بهینه‌ساز Adam و نرخ یادگیری ۰/۰۰۱ انجام می‌شود. برای جلوگیری از بیش‌برازش و صرفه‌جویی در زمان، از EarlyStopping روی خطای اعتبارسنجی با $\text{patience} = 3$ استفاده می‌شود، یعنی اگر سه ایپوک متوالی بهبودی در val_loss حاصل نشود، آموزش متوقف می‌شود. حداکثر تعداد ایپوک‌ها نیز ۲۰ تعیین شد تا چارچوب زمانی آموزش در حد معقولی باقی بماند.

۲.۴ خطوط مبنای مقایسه

برای اینکه برتری مدل پیشنهادی به‌درستی سنجیده شود، دو خط مبنای مقایسه در نظر گرفته شد.

جدول ۳- خطوط مبنای مقایسه

خط مبنا	توصیف
NaiveLastValue	ساده‌ترین خط مبنا که صرفاً آخرین مقدار مشاهده‌شده را برای همه‌ی گام‌های افق تکرار میکند
LSTM ساده (بدون وزندهی)	LSTM با معماری کاملاً یکسان با مدل پیشنهادی LSTM+GHW، اما بدون مکانیزم وزندهی تا تفاوت عملکرد صرفاً به GHW نسبت داده شود

همچنین برابری کامل معماری (تعداد لایه‌ها، تعداد واحدها و ساختار) بین LSTM ساده و LSTM+GHW حفظ شده است؛ در این صورت، هر اختلافی در نتایج فقط می‌تواند از تابع زیان وزن‌دار نشئت بگیرد، نه از تغییر ساختار شبکه.

۳.۴ معیارهای ارزیابی

۱.۳.۴ معیارهای گرادیانی (روی مقیاس نرمال‌شده):

برای هر افق، دو معیار MAE و RMSE هم به‌صورت میانگین کل و هم به‌تفکیک گام اول و گام آخر افق گزارش شد. گزارش تفکیکی این امکان را می‌دهد که انباشت خطا در طول افق به‌وضوح دیده شود، انتظار می‌رود خطای گام آخر به‌مراتب بزرگتر از گام اول باشد.

۲.۳.۴ معیارهای تکمیلی (روی مقادیر واقعی و غیر نرمال‌شده):

برای تفسیر بهتر نتایج از دید کاربر، سه معیار روی مقادیر denormalized محاسبه شده است. اولین معیار R (ضریب تعیین) که درصد واریانس داده‌ای که مدل توضیح می‌دهد. دومین معیار SMAPE (خطای درصدی متقارن) به این دلیل انتخاب شد که برخلاف MAPE، وقتی مقدار واقعی به صفر نزدیک است (مثلاً دمای نزدیک صفر)، دچار بی‌نهایت و ناپایداری نمی‌شود و عملکرد ایمنتری دارد. سومین معیار دقت که به‌صورت $100 - \text{SMAPE}$ تعریف می‌شود تا به‌شکلی شهودی‌تر گزارش شود.

همچنین برای اینکه نتایج دقیقاً قابل تکرار باشند، seed تصادفی ثابت در سراسر آزمایشها تنظیم شد که با فعالسازی حالت قطعی (deterministic) فریمورک، رفتار جزئیات محاسبات کاهنده (مثل پیمایش دادهها و نویز اولیه‌سازی) را نیز تثبیت می‌کند تا خروجی در اجراهای مکرر یکسان بماند.

۴.۳.۴ محیط اجرا

پیاده‌سازی‌ها عملاً روی Google Colab اجرا شدند. به‌منظور بازتولیدپذیری کامل محیط نسخه‌های کتابخانه‌ها به‌صورت زیر تعریف می‌شود. پین کردن نسخه‌ها تضمین می‌کند که در هر جلسه‌ی اجرایی، رفتار کتابخانه‌ها یکسان باقی بماند و مقایسه‌ی نتایج بین اجراهای مختلف معتبر باشد.

جدول ۳- نسخه‌های کتابخانه‌ها


کتابخانه	نسخه
TensorFlow	۲/۱۶/۱
Arch	۶/۳/۰
Pandas	۲/۲/۲
Numpy	۱/۲۶/۴
Matplotlib	۳/۸/۴

۵. نتایج

جدول ۴- نتایج افق ۶ گام

مدل	MAE میانگین	RMSE میانگین	MAE گام اول	MAE گام آخر	رشد خطا	R ²	SMAPE
Baseline (تکرار آخرین مقدار)	۱.۲۵۹۸	۱.۵۹۶۳	۱.۲۸۶۳	۱.۲۳۰۶	-۰.۵۵۷	-۱.۷۳۳۴	٪۵۸.۰۸
LSTM	۰.۱۹۳۵	۰.۲۸۸۰	۰.۱۱۰۸	۰.۲۵۷۹	۰.۱۴۷۱+	۰.۹۱۲۲	٪۱۱.۶۸
GRU	۰.۱۹۳۰	۰.۲۸۷۱	۰.۱۰۵۵	۰.۲۶۰۱	۰.۱۵۴۶+	۰.۹۱۲۶	٪۱۱.۶۴
Seq2Seq	۰.۱۹۰۱	۰.۲۸۴۹	۰.۱۰۶۹	۰.۲۵۳۲	۰.۱۴۶۳+	۰.۹۱۴۲	٪۱۱.۴۸
LSTM + فقط-افق (ablation)	۰.۱۹۴۴	۰.۲۸۷۰	۰.۱۰۷۸	۰.۲۶۱۱	۰.۱۵۳۳+	۰.۹۱۲۷	٪۱۱.۸۱
LSTM + فقط-نوسان (ablation)	۰.۱۹۳۵	۰.۲۸۷۹	۰.۱۰۴۵	۰.۲۶۰۲	۰.۱۵۵۷+	۰.۹۱۲۱	٪۱۱.۵۱
LSTM + GHW ترکیبی (مشارکت اصلی)	۰.۱۹۳۲	۰.۲۸۷۸	۰.۱۰۴۹	۰.۲۵۹۸	۰.۱۵۴۹+	۰.۹۱۲۲	٪۱۱.۷۱

نتایج افق ۶ گام، دو دهه کاملاً متفاوت از عملکرد را نشان میدهد که خط فاصلشان بین خط مبنای ساده و مدل‌های بازگشتی است. خط مبنای Naive (تکرار آخرین مقدار) با MAE میانگین ۱،۲۵۹۸، ضریب تعیین ۱۰۷۳- و SMAPE حدود ۵۸٪ شکست کاملی را ثبت می‌کند یعنی حتی از پیش‌بینی مقدار میانگین هم بدتر عمل کرده و عملاً هیچ اطلاعاتی در بازه‌ی ۶ ساعته قابل تکرار نیست. در مقابل، هر چهار مدل بازگشتی LSTM، GRU، Seq2Seq و LSTM+GHW با MAE حدود (۰،۱۹-۰،۱۹۵) و دقت حدود ۸۸٪ به سطحی تقریباً اشباع شده از عملکرد رسیده‌اند که در آن تفاوت مدل‌ها در محدوده‌ی نویز آماری (حداکثر ۲٪) قرار می‌گیرد؛ در این میان Seq2Seq با MAE ۰،۱۹۰۱ و SMAPE ۱۱،۴۸٪ بهترین عملکرد را دارد و مدل پیشنهادی LSTM+GHW MAE ۰،۱۹۳۲ در رتبه‌ی میانی قرار می‌گیرد. جالب‌ترین مشاهدات دو مورد است: نخست، الگوی انباشت خطا که در آن خطای گام آخر همگی مدل‌های بازگشتی حدوداً ۲،۳ تا ۲،۵ برابر گام اول است و رشد خطای مثبت و مشهود در مقابل رشد تقریباً صفر Naive، بازگشتی بودن ماهیت این خطا را تأیید میکند؛ دوم، یافته‌ی ضدشهودی ablation که در آن وزن افقی تنها horizon_only نه تنها به گام آخر کمکی نکرد MAE ۰،۲۶۱۱ در برابر ۰،۲۵۷۹ مدل ساده بلکه بدترین میانگین را بین همگی مدل‌های یادگیری ثبت کرد، شواهدی که نشان می‌دهد در افق کوتاه، فشار مضاعف روی گام‌های دور گرادیان را مخدوش میکند. این یافته‌ها نشان می‌دهد افق ۶ گام یک افق اشباع است که در آن همگی مدل‌های بازگشتی به سطح مشترکی از عملکرد میرسند و مزیت GHW هنوز قابل‌اندازه‌گیری نیست؛ به همین دلیل، آزمون واقعی این مکانیزم با افق‌های بلندتر، یعنی ۲۴ و ۷۲ گام، رقم خواهد خورد.




شکل ۱- روند تغییرات MAE بر حسب گام افق برای همه‌ی مدل‌ها در افق ۶ گام

در افق ۶ گام، نتایج کمی و الگوی دیداری شکل ۱ کاملاً همسو هستند. همان‌طور که جدول ۱ نشان داد، خط مبنای NaiveLastValue با فاصله‌ای بسیار زیاد از همه‌ی مدل‌های یادگیری قرار دارد و MAE آن در تمام گام‌ها حول مقادیر بسیار بالا باقی می‌ماند، در حالی که مدل‌های بازگشتی همگی در بازه‌ای فشرده و نزدیک به هم متمرکز شده‌اند. شکل ۱ به‌خوبی نشان می‌دهد که برای LSTM، GRU، Seq2Seq و نسخه‌های مختلف GHW، خطا از گام اول تا گام ششم به‌صورت تدریجی افزایش می‌یابد؛ بنابراین، پدیده‌ی انباشت خطا در پیش‌بینی چندمرحله‌ای به‌صورت بصری نیز تأیید می‌شود. در مقابل، منحنی baseline تقریباً تخت و حتی اندکی کاهشی است که نشان می‌دهد این روش ساده اساساً دینامیک افق را مدل نمی‌کند و فقط در کل عملکرد ضعیفی دارد. همچنین هم‌پوشانی شدید منحنی‌های LSTM، GRU، Seq2Seq و سه نسخه‌ی ablation نشان می‌دهد که در افق کوتاه ۶ گام، اختلاف عملکرد این مدل‌ها بسیار ناچیز است و مزیت روش پیشنهادی GHW هنوز به‌صورت برجسته ظاهر نشده است. در نتیجه، افق ۶ گام را می‌توان یک افق نسبتاً اشباع دانست که در آن مدل‌های بازگشتی همگی به سطح مشابهی از دقت رسیده‌اند، در حالی که خطای آن‌ها همچنان با دور شدن از گام نخست به‌طور منظم افزایش پیدا می‌کند.

مدل	MAE میانگین	RMSE میانگین	MAE گام اول	MAE گام آخر	رشد خطا	R ²	SMAPE
Baseline (تکرار آخرین مقدار)	۱.۲۲۶۰	۱.۵۳۸۱	۱.۲۸۳۵	۱.۲۵۴۵	-۰.۰۲۸۹	-۱.۵۵۲۷	%۵۷.۳۹
LSTM	۰.۳۱۱۵	۰.۴۳۰۰	۰.۱۲۹۱	۰.۳۷۵۸	+۰.۲۴۶۷	۰.۸۰۶۶	%۱۸.۵۱
GRU	۰.۳۰۴۹	۰.۴۲۳۲	۰.۱۱۹۴	۰.۳۷۳۵	+۰.۲۵۴۱	۰.۸۱۲۰	%۱۷.۹۶
Seq2Seq	۰.۳۰۷۹	۰.۴۲۹۴	۰.۱۴۳۷	۰.۳۷۷۶	+۰.۲۳۴۰	۰.۸۰۷۰	%۱۸.۳۹
LSTM + فقط-افق (ablation)	۰.۳۱۳۳	۰.۴۳۴۵	۰.۱۳۴۹	۰.۳۷۵۰	+۰.۲۴۰۰	۰.۸۰۲۵	%۱۸.۹۶
LSTM + فقط-نوسان (ablation)	۰.۳۱۴۲	۰.۴۳۸۲	۰.۱۳۱۴	۰.۳۸۴۵	+۰.۲۵۳۱	۰.۷۹۸۸	%۱۸.۹۰
LSTM + GHW ترکیبی (مشارکت اصلی)	۰.۳۱۷۴	۰.۴۳۹۵	۰.۱۴۴۳	۰.۳۷۸۷	+۰.۲۳۴۴	۰.۷۹۸۳	%۱۸.۸۲

در جدول ۵، دشواری پیش‌بینی به‌وضوح افزایش یافته و میانگین خطای تمام مدل‌ها نسبت به افق ۶ گام حدود ۶۰٪ رشد داشته است. MAE از محدوده ۰.۱۹ به ۰.۳۱ رسیده است. در این بخش نیز خط مبنای Naive با MAE ۱.۲۲۶۰ و ضریب تعیین منفی ۱.۵۵- همچنان ناکارآمدی مطلق خود را در پیش‌بینی‌های روزانه نشان می‌دهد. در میان مدل‌های یادگیری، MAE با GRU ۰.۳۰۴۹ و دقت %۸۲.۰۴ SMAPE ۱۷.۹۶٪ بهترین عملکرد کل را ثبت کرده است اما تحلیل مدل پیشنهادی GHW در این افق، نتایج غیرمنتظره‌ای به همراه دارد؛ برخلاف فرضیه‌ی اولیه، مدل LSTM+GHW با MAE ۰.۳۱۷۴ نه تنها از رقبای خود پیشی نگرفته، بلکه نسبت به LSTM ساده MAE ۰.۳۱۱۵ حدود ۲٪ ضعیف‌تر عمل کرده است. همچنین رشد خطا نشان‌دهنده یک نکته‌ی فنی مثبت است. مدل ترکیبی GHW با رشد خطای ۰.۲۳۴۴ موفق شده است نرخ افزایش خطا از گام اول تا آخر را نسبت به LSTM ساده ۰.۲۴۶۷ و GRU ۰.۲۵۴۱ مهار کند، اما به دلیل خطای بالاتر در گام‌های ابتدایی ۰.۱۴۴۳، در مجموع میانگین ضعیف‌تری را ثبت کرده است. نتایج Ablation نیز نشان می‌دهد که در این افق، هر دو مکانیزم وزن‌دهی افقی و نوسانی به تنهایی و در ترکیب با هم، اندکی باعث تخریب عملکرد کل شده‌اند. این مشاهدات حاکی از آن است که در افق یک‌روزه، پیچیدگی حاصل از اعمال وزن‌های آماری GARCH هنوز نتوانسته است بر نویز داده غلبه کند و مدل ساده‌تر LSTM یا GRU با ساختار بازگشتی استاندارد خود، بازدهی بالاتری نشان می‌دهند.




شکل ۱- روند تغییرات MAE بر حسب گام افق برای تمامی مدل‌ها در افق ۲۴ گام

در افق ۲۴ گام، الگوی شکل ۲ و اعداد جدول کاملاً یک پیام مشترک را منتقل می‌کنند: با افزایش افق پیش‌بینی، مسئله به مراتب دشوارتر می‌شود و خطای مدل‌ها به صورت تدریجی انباشته می‌گردد. در این میان، **baseline** همچنان در سطحی بسیار بالاتر از سایر مدل‌ها باقی مانده و با MAE میانگین ۱.۲۲۶۰ و R^2 منفی ۱.۵۵۲۷ عملاً ناتوانی خود را در مدل‌سازی دینامیک زمانی نشان می‌دهد؛ با این حال، منحنی آن در شکل ۲ تقریباً تخت و کمی U-شکل است، به این معنا که این روش ساده نه از ساختار افق‌های مختلف پیروی می‌کند و نه روند واقعی تغییرات را می‌فهمد. در مقابل، تمامی مدل‌های بازگشتی از جمله LSTM، GRU، Seq2Seq و نسخه‌های مبتنی بر GHW در یک خوشه‌ی فشرده و نزدیک به هم قرار گرفته‌اند و MAE آن‌ها از حدود ۰.۱۲-۰.۱۴ در گام‌های ابتدایی به حدود ۰.۳۷-۰.۳۸ در گام‌های پایانی می‌رسد؛ این افزایش یکنواخت نشان‌دهنده‌ی انباشت خطا در پیش‌بینی چندمرحله‌ای است. از دید عملکرد کلی، GRU با MAE میانگین ۰.۳۰۴۹، RMSE ۰.۴۲۳۲، R^2 برابر ۰.۸۱۲۰ و SMAPE برابر ۱۷.۹۶٪ بهترین نتیجه را ثبت کرده است، اما تفاوت آن با LSTM و Seq2Seq بسیار محدود است و مزیت قاطعی دیده نمی‌شود. نکته‌ی مهم‌تر این است که مدل پیشنهادی LSTM+GHW در این افق، با وجود موفقیت نسبی در کنترل شیب رشد خطا نسبت به برخی رقبای، در میانگین کلی دقت برتری پیدا نکرده و حتی اندکی ضعیف‌تر از LSTM ساده ظاهر شده است؛ به بیان دقیق‌تر، GHW توانسته افزایش خطا را تا حدی مهار کند، اما به دلیل خطای بالاتر در گام‌های ابتدایی، سود این مهار در عملکرد نهایی جبران نشده است. در نتیجه، شکل ۲ نشان می‌دهد که در افق ۲۴ گام، تمامی مدل‌های یادگیری به یک سطح عملکرد نزدیک رسیده‌اند، اما هنوز هیچ‌کدام از جمله نسخه‌ی ترکیبی GHW، نتوانسته‌اند بهبود معناداری نسبت به مدل‌های بازگشتی استاندارد ایجاد کنند.

جدول ۶- نتایج ۷۲ گام افق

مدل	MAE میانگین	RMSE میانگین	MAE گام اول	MAE گام آخر	رشد خطا	R ²	SMAPE
Baseline (تکرار آخرین مقدار)	۱.۲۰۱۴	۱.۴۹۶۰	۱.۲۷۲۲	۱.۲۳۳۰	-۰.۳۹۳-	۱.۴۱۵۸-	%۵۶.۷۹
LSTM	۰.۳۹۰۸	۰.۵۲۰۴	۰.۱۸۰۱	۰.۴۴۵۱	۰.۲۶۵۰+	۰.۷۱۷۴	%۲۳.۴۸
GRU	۰.۳۸۶۸	۰.۵۱۲۱	۰.۱۴۷۱	۰.۴۴۶۹	۰.۲۹۹۹+	۰.۷۲۵۷	%۲۳.۰۳
Seq2Seq	۰.۳۹۵۱	۰.۵۲۲۵	۰.۲۱۳۲	۰.۴۵۷۰	۰.۲۴۳۷+	۰.۷۱۵۸	%۲۳.۳۴
LSTM + فقط-افق (ablation)	۰.۳۹۹۰	۰.۵۲۶۹	۰.۲۰۵۰	۰.۴۵۱۳	۰.۲۴۶۳+	۰.۷۱۰۸	%۲۳.۸۳
LSTM + فقط-نوسان (ablation)	۰.۳۹۸۲	۰.۵۲۷۳	۰.۱۸۳۵	۰.۴۵۲۲	۰.۲۶۸۷+	۰.۷۰۹۶	%۲۴.۱۰
LSTM + GHW ترکیبی (مشارکت اصلی)	۰.۳۹۵۴	۰.۵۲۴۵	۰.۱۸۲۹	۰.۴۵۰۰	۰.۲۶۷۱+	۰.۷۱۳۱	%۲۳.۷۲

در طولانی‌ترین افق پیش‌بینی (۷۲ گام)، با افزایش شدید عدم قطعیت و پیچیدگی دینامیک سیستم، میانگین خطای تمام مدل‌ها نسبت به افق ۲۴ گام حدود ۲۵ تا ۲۸ درصد رشد داشته است. در این سناریو، خط مبنای **Baseline** همچنان عملکرد ضعیف خود را با **MAE** میانگین ۱.۲۰۱۴ و ضریب تعیین منفی ۱.۴۱۵۸- ادامه می‌دهد. در میان مدل‌های یادگیری عمیق، مدل **GRU** با کسب کمترین خطای میانگین **MAE** برابر ۰.۳۸۶۸ و بالاترین ضریب تعیین **R²** برابر ۰.۷۲۵۷، همچنان برترین مدل از نظر معیارهای نقطه‌ای و توزیعی کل است. با این حال، تحلیل متغیرهای رشد خطا و رفتار مدل‌ها در طول گام‌های افق، نکات فنی مهمی را آشکار می‌سازد؛ مدل **GRU** اگرچه در گام‌های اولیه بسیار دقیق عمل می‌کند (**MAE** گام اول ۰.۱۴۷۱)، اما با رشد خطای شدید ۰.۲۹۹۹ مواجه است و در گام پایانی به خطای ۰.۴۴۶۹ می‌رسد. در مقابل، مدل **Seq2Seq** با رشد خطای ۰.۲۴۳۷ و مدل **LSTM** + فقط-افق (**Ablation**) با رشد خطای ۰.۲۴۶۳، توانسته‌اند شیب انباشت خطا را بهتر کنترل کنند. مدل پیشنهادی **LSTM+GHW** ترکیبی با **MAE** میانگین ۰.۳۹۵۴ عملکردی بهتر از هر دو نسخه‌ی تک‌معیاری **Ablation** (فقط افق با خطای ۰.۳۹۹۰ و فقط-نوسان با خطای ۰.۳۹۸۲) نشان داده است؛ این امر تایید می‌کند که تلفیق هم‌زمان وزن‌دهی افق و واریانس ناهمسانی **GARCH** اثربخشی بیشتری نسبت به استفاده‌ی مجزای آن‌ها دارد، هرچند که در نهایت نتوانسته بر ساختار ساده‌تر و بهینه‌ی **GRU** پیشی بگیرد. نتایج کلی این بخش نشان می‌دهد که با افزایش افق پیش‌بینی به ۷۲ گام، اثر نوسانات کوتاه‌مدت کاهش یافته و مدل‌های بازگشتی با چالش جدی انباشت خطا در گام‌های انتهایی مواجه هستند که معماری‌های متکی بر انتقال حالت (مانند **GRU**) یا ساختارهای مفیدتر را ترجیح می‌دهند.



شکل ۳- روند تغییرات MAE بر حسب گام افق برای تمامی مدل‌ها در افق ۷۲ گام

در بررسی بصری افق ۷۲ گام در شکل ۳، چند پدیده‌ی آماری و معماری برجسته قابل مشاهده است. نخست، رفتار مدل Baseline است که برخلاف افق‌های کوتاه‌تر، در اینجا یک الگوی نوسانی و متناوب (سینوسی) از خود نشان می‌دهد؛ این نوسان بیانگر آن است که روش تکرار آخرین مقدار به دلیل ماهیت چرخه‌ای (Cyclical) داده‌های هواشناسی، در ساعاتی از شبانه‌روز به مقدار واقعی نزدیک و در ساعاتی دیگر به شدت از آن دور می‌شود، هرچند که در مجموع با MAE بالای ۱.۲، همچنان فاقد ارزش عملیاتی است. در مقابل، خوشه‌ی مدل‌های بازگشتی (RNNs) رفتار بسیار پایدارتری دارند. همان‌طور که در نمودار مشهود است، مدل GRU (منحنی سبز) در گام‌های ابتدایی برتری محسوس دارد و با کمترین خطا کار خود را آغاز می‌کند، اما با حرکت به سمت انتهای افق ۷۲ گام، شیب افزایش خطای آن تندتر شده و در نهایت با سایر مدل‌ها در محدوده‌ی خطای ۰.۴۵ تلاقی می‌کند. این پدیده نشان‌دهنده‌ی چالش انباشت خطا است که در آن، با گذشت ۳ روز از لحظه‌ی پیش‌بینی، تفاوت‌های ساختاری میان LSTM، GRU و نسخه‌های GHW به حداقل رسیده و تمامی مدل‌ها به یک سطح اشباع از خطا می‌رسند. همچنین، هم‌پوشانی نزدیک منحنی‌های GHW (ترکیبی و تک‌معیاره) با مدل LSTM ساده در طول افق، تأیید می‌کند که اگرچه وزن‌دهی آماری در مهار مقطعی نوسانات مؤثر بوده، اما در افق‌های بسیار طولانی، عدم قطعیت ذاتی داده‌ها بر پیچیدگی‌های تابع زیان غلبه کرده است.

جدول ۷- مقایسه نهایی و جمع‌بندی عملکرد در افق‌های مختلف

تفاوت	MAE مدل GHW	MAE بهترین مدل	بهترین مدل (کمترین MAE)	افق
۰.۰۰۳۱+ (GHW ضعیف‌تر)	۰.۱۹۳۲	۰.۱۹۰۱	Seq2Seq	۶ گام
۰.۰۱۲۵+ (GHW ضعیف‌تر)	۰.۳۱۷۴	۰.۳۰۴۹	GRU	۲۴ گام
۰.۰۰۸۶+ (GHW ضعیف‌تر)	۰.۳۹۵۴	۰.۳۸۶۸	GRU	۷۲ گام

در یک نگاه کلی به عملکرد مدل‌ها در سه افق ۶، ۲۴ و ۷۲ گام، نتایج حاکی از برتری معماری‌های بازگشتی استاندارد در پیش‌بینی متغیرهای هواشناسی است. مطابق با جدول ۷، در افق کوتاه‌مدت (۶ گام)، مدل Seq2Seq با MAE ۰.۱۹۰۱ بهترین عملکرد را

ثبت کرده است، در حالی که با افزایش طول افق به ۲۴ و ۷۲ گام، مدل GRU با حفظ پایداری بالاتر، به عنوان دقیق‌ترین مدل (به ترتیب با خطای ۰.۳۰۴۹ و ۰.۳۸۶۸) شناخته می‌شود. تحلیل جایگاه مدل پیشنهادی LSTM+GHW ترکیبی نشان می‌دهد که اگرچه این مدل در تمامی افق‌ها عملکردی بسیار نزدیک به بهترین مدل‌ها داشته (با اختلافی در محدوده ۰.۰۰۳ تا ۰.۰۱۲ واحد MAE)، اما موفق به شکست دادن رقبا نشده است. نکته‌ی حائز اهمیت این است که بیشترین شکاف میان مدل GHW و بهترین مدل در افق میان‌مدت (۲۴ گام) رخ داده است (۰.۰۱۲۵+); اما با رسیدن به افق ۷۲ گام، این شکاف مجدداً کاهش یافته و به ۰.۰۰۸۶ رسیده است. این روند نشان می‌دهد که رویکرد وزن‌دهی ترکیبی GHW، علی‌رغم پیچیدگی محاسباتی و تثوریک، در افق‌های بسیار طولانی عملکرد پایداری نسبت به افق‌های میان‌مدت از خود نشان می‌دهد. در مجموع، می‌توان نتیجه گرفت که برای دیتاست Jena Climate، ساختار درونی سلول‌های GRU در استخراج وابستگی‌های زمانی طولانی‌مدت کارآمدتر از اصلاحات در تابع زیان بر پایه‌ی مدل‌های واریانس ناهمسان (GARCH) عمل کرده است.

۸. تحلیل انتقادی، محدودیت‌ها و صداقت علمی

۱.۸ تقابل فرضیه و واقعیت تجربی

در طراحی اولیه این پژوهش (مطابق بخش ۳.۳.۲)، فرضیه اصلی بر این اساس استوار بود که تلفیق وزن‌دهی فزاینده افق و وزن‌دهی معکوس واریانس GARCH (مدل GHW+LSTM) می‌تواند با مهار انباشت خطا در گام‌های دورتر و تمرکز بر بازه‌های پرنوسان، عملکردی برتر نسبت به LSTM ساده و نسخه‌های تک‌مکانیزمی (ablation) ارائه دهد و این برتری در افق‌های بلندتر نمایان‌تر شود. همچنین نتایج تجربی حاصل از پیاده‌سازی روی داده‌های Jena Climate این فرضیه را به طور کامل رد کرد. در هر سه افق پیش‌بینی، مدل‌های استاندارد بدون وزن‌دهی پیش‌تاز بودند؛ به طوری که در افق ۶ گام مدل Seq2Seq و در افق‌های ۲۴ و ۷۲ گام مدل GRU بهترین عملکرد را ثبت کردند. مدل پیشنهادی ترکیبی GHW+LSTM نه تنها نتوانست از این رقبا استاندارد پیشی بگیرد، بلکه در افق‌های ۲۴ و ۷۲ گام حتی نسبت به مدل LSTM ساده (بدون هیچ‌گونه وزن‌دهی) عملکرد ضعیف‌تری نشان داد. این تضاد، هسته اصلی ارزش علمی این گزارش را شکل می‌دهد. در افق ۶ گام (کوتاه‌مدت): تفاوت میان مدل‌ها بسیار ناچیز است (دامنه تغییرات MAE بین ۰.۱۹۰۱ تا ۰.۱۹۴۴). در این افق کوتاه، رفتارهای نوسانی پیچیده هنوز فعال نشده‌اند و اثر وزن‌دهی GHW در حد نویز آماری است. در افق ۲۴ گام (میان‌مدت) مدل GRU با خطای $MAE=0.3049$ برترین مدل است و در مقابل، مدل ترکیبی GHW+LSTM با خطای ۰.۳۱۷۴۰ در انتهای جدول قرار می‌گیرد. این مدل حتی از LSTM ساده (۰.۳۱۱۵) و هر دو نسخه تک‌مکانیزمی ضعیف‌تر عمل کرده است. در افق ۷۲ گام بلندمدت الگوی مشابهی تکرار می‌شود؛ GRU با خطای ۰.۳۸۶۸ پیش‌تاز است و مدل ترکیبی با خطای ۰.۳۹۵۴۰.۳۹۵۴۰.۳۹۵۴۰ ضعف خود را در برابر LSTM ساده (۰.۳۹۰۸) حفظ می‌کند. در تحلیل آزمون حذفی نتایج نشان می‌دهند ضعف عملکرد، ناشی از فرآیند ترکیب وزن‌ها نیست؛ چرا که در تمام افق‌ها، هر دو نسخه تک‌مکانیزمی (فقط‌افق و فقط‌نوسان) نیز عملکردی ضعیف‌تر یا حداکثر هم‌سطح با LSTM ساده داشته‌اند. این یعنی خود ایده اعمال وزن روی نمونه‌ها (weightsample) با رویکرد فعلی کارآمد نبوده است.

۲.۸ تحلیل علل ریشه‌ای عدم موفقیت فرضیه

چند عامل فنی و ساختاری می‌توانند توجیه‌کننده شکست فرضیه GHW در این آزمایش باشند:

۱. حساسیت شدید به هایپر پارامتر مقیاس (α): ضریب تنظیم وزن دهی ($\alpha=1$) ممکن است وزن ها را بیش از حد تهاجمی (ایجاد نوسان شدید در گرادیان) یا بیش از حد ملایم (بی اثر بودن وزن دهی) کرده باشد. عدم اجرای جستجوی شبکه ای سیستماتیک برای یافتن α بهینه، محدودیت اصلی این آزمایش است.
۲. نایکتوختی فضای بهینه سازی و محدودیت آموزش: اعمال $weightsample$ ذاتاً فضای بهینه سازی تابع هزینه را ناهموارتر می کند. در این شرایط، مدل برای همگرایی به زمان بیشتر یا نرخ یادگیری متفاوتی نیاز دارد. با توجه به استفاده از مکانیزم $EarlyStopping$ با $patience=3$ ، احتمالاً مدل GHW پیش از رسیدن به نقطه بهینه محلی مناسب، فرآیند آموزش را متوقف کرده است.
۳. تفاوت رژیم پسماندها: سیگنال های نوسان GARCH بر پایه پسماندهای یک مدل مرجع جداگانه ساخته شده اند. اگر رژیم های پرنوسان آن مدل با LSTM نهایی هم راستا نبوده باشد، فرآیند وزن دهی به جای هدایت مدل به سمت نقاط سخت، نویز مخربی را به فرآیند انتشار خطا تزریق کرده است.
۴. تفوق ساختاری سلول GRU: یک یافته جانبی اما کلیدی، برتری مطلق GRU در تمام افق ها با بودجه آموزشی و تعداد واحدهای برابر با LSTM است. گیت های ساده تر و تعداد پارامترهای کمتر GRU نشان داد که برای داده های آب و هوایی Jena، معماری ساده تر پایداری و تعمیم پذیری بهتری نسبت به مکانیزم پیچیده تر LSTM (با یا بدون تابع زیان پیشنهادی) ارائه می دهد.

۳.۸ محدودیت های پژوهش

علاوه بر چالش های مدل پیشنهادی، محدودیت های زیر بر کلیت تعمیم پذیری نتایج سایه تاثیر دارند:

- محدودیت جغرافیایی داده ها: ارزیابی مدل ها صرفاً بر روی یک ایستگاه هواشناسی (Jena Climate) انجام شده است. برای اثبات کارآمدی یا ناکارآمدی مطلق یک تابع زیان، نیاز به ارزیابی چند ایستگاهی و چند اقلیمی است.
- عدم ارزیابی کمی بازه های اطمینان: اگرچه تابع پاداش بازه اطمینان در سطح کد توسعه یافته است، اما در این گزارش ارزیابی کمی و عددی از میزان پوشش تجربی بازه ها ارائه نشده است.
- اتکا به پروکسی در تحلیل نواحی شکست: در بخش تحلیل جبهه های هوایی ناگهانی، دهک بالای واریانس شرطی GARCH (σ_t) به عنوان پروکسی جبهه هوا فرض شده است. در حالی که نوسان بالا می تواند ناشی از خطای حسگر یا نویزهای لحظه ای باشد. برای تایید دقیق علمی، باید تاریخ و ساعت این بازه ها به طور دستی با متغیرهای فیزیکی خام (نظیر افت ناگهانی فشار یا تغییر جهت باد) تطبیق داده می شد.

۹. نتیجه گیری

این پروژه مسیر استاندارد یک تحقیق علمی را پیمود: تعریف فرضیه شفاف، آزمون تجربی دقیق به همراه آزمون های حذفی و مواجهه صادقانه با رد فرضیه یافته نهایی این است که دست کم با تنظیمات هایپر پارامتری فعلی و بر روی این مجموعه داده، ایده اصلاح تابع زیان به کمک مدل سازی GARCH سودی به همراه نداشته و بهبودهای عملکردی نه از سمت توابع زیان ابداعی، بلکه از انتخاب معماری پایه مناسب تر (سلول های بازگشتی GRU) حاصل می شود.

[۱] Engle, R. F. (۱۹۸۲). Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation. *Econometrica*, ۵۰(۴), ۹۸۷-۱۰۰۷.

[۲] Bollerslev, T. (۱۹۸۶). Generalized Autoregressive Conditional Heteroskedasticity. *Journal of Econometrics*, ۳۱(۳), ۳۰۷-۳۲۷.

[۳] Hochreiter, S., & Schmidhuber, J. (۱۹۹۷). Long Short-Term Memory. *Neural Computation*, ۹(۸), ۱۷۳۵-۱۷۸۰.

[۴] Cho, K., van Merriënboer, B., Gulcehre, C., et al. (۲۰۱۴). Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation. *Proceedings of EMNLP 2014*.

[۵] Sutskever, I., Vinyals, O., & Le, Q. V. (۲۰۱۴). Sequence to Sequence Learning with Neural Networks. *Advances in Neural Information Processing Systems (NeurIPS)* 27.

[۶] Vaswani, A., Shazeer, N., Parmar, N., et al. (۲۰۱۷). Attention Is All You Need. *Advances in Neural Information Processing Systems (NeurIPS)* 30.

[۷] Sheppard, K., Khrapov, S., Lipták, G., et al. *arch: A Python package for ARCH/GARCH models in Python*. <https://github.com/bashtage/arch>

[۸] Abadi, M., Agarwal, A., Barham, P., et al. *TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems (tf.keras)*. نسخه‌ی استفاده‌شده مطابق requirements.txt: tensorflow==۲,۱۶,۱.

[۹] TensorFlow “Time series forecasting” tutorial (پیش‌پردازش، windowing منبع الهام‌بخش ساختار). (بازنویسی‌شده از صفر در این پروژه). https://www.tensorflow.org/tutorials/structured_data/time_series